

Sistema local de auditoría técnica de informes mamográficos en español mediante NLP: coherencia entre la categoría BI-RADS y la recomendación clínica

Sebastián Inostroza Hurtado

Abstract—El cáncer de mama es la principal causa de mortalidad oncológica femenina en América Latina. La información crítica de los informes mamográficos (la categoría BI-RADS y la recomendación clínica) queda habitualmente atrapada como texto libre, lo que dificulta su explotación por sistemas administrativos y la detección automática de inconsistencias entre el diagnóstico y la conducta sugerida. Este trabajo presenta un sistema de procesamiento de lenguaje natural ejecutable localmente que audita técnicamente la coherencia interna de los informes mamográficos en español, contrastando la categoría BI-RADS declarada por el radiólogo con la recomendación clínica emitida bajo el estándar BI-RADS/ACR. El objetivo es una herramienta aplicable a la semántica clínico-radiológica latinoamericana, con Chile como contexto de despliegue previsto, apoyándose en la uniformidad regional que induce la adopción del estándar BI-RADS/ACR. El pipeline integra cuatro módulos: un extractor de categoría BI-RADS por reglas con tolerancia a variaciones tipográficas; un extractor de recomendaciones con tres capas de procesamiento (normalización, reglas clínicas y similitud semántica TF-IDF); un motor de cotejo contra una tabla que formaliza el estándar BI-RADS/ACR; y un extractor NER basado en DistilBETO que localiza la recomendación en redacciones no anticipadas por las reglas. Evaluado sobre 4357 informes en español de un corpus público paraguayo, el sistema alcanzó Macro F1 de 0,9995 en la extracción de BI-RADS por reglas y F1 de span de 0,9991 en la localización neuronal de la recomendación. Un verificador Transformer entrenado para contrastar la extracción reglada (Macro F1 = $0,8877 \pm 0,0501$ bajo validación cruzada de 5 particiones) se retiró del pipeline tras medir por cuatro vías que no aporta sobre las reglas, resultado que se reporta por su valor metodológico. El sistema generó alertas clínicas en el 1,15 % de los informes, un nivel bajo de fatiga de alertas [1]. La ejecución local facilita el cumplimiento de normativas de protección de datos como la Ley N.º 19.628 en Chile. Como limitación, el corpus es de origen paraguayo y no chileno, por lo que la validación sobre informes locales queda como trabajo futuro. El resultado es una herramienta interpretable y auditable de control de calidad para programas de tamizaje mamográfico.

Index Terms—NLP clínico, BI-RADS, informes mamográficos, auditoría técnica, DistilBETO, español clínico, salud digital.

I. INTRODUCCIÓN

EL cáncer de mama es la primera causa de mortalidad por tumores malignos en mujeres en América Latina, y en Chile en particular exhibe tasas con un crecimiento sostenido en la última década [2]. El tamizaje mamográfico

constituye la principal estrategia poblacional de detección temprana, y la calidad del informe radiológico —particularmente la categoría BI-RADS asignada y la recomendación clínica emitida— determina directamente la conducta de seguimiento. Garantizar la coherencia interna entre estos dos elementos es, por tanto, una preocupación clínica de primer orden en toda la región.

En la práctica asistencial, los informes mamográficos se generan como texto libre estructurado en bloques (hallazgos, conclusión, recomendaciones), donde la categoría BI-RADS y la recomendación clínica quedan atrapadas en lenguaje natural. Esto dificulta su explotación por sistemas administrativos del centro asistencial y, más relevante, imposibilita la auditoría automática de coherencia entre lo que el radiólogo concluyó y lo que recomendó. Un BI-RADS 4 (sospechoso) acompañado de una recomendación de *control anual* ilustra el tipo de inconsistencia que un sistema de validación técnica podría detectar, y que actualmente solo se identifica mediante revisión manual.

El procesamiento de lenguaje natural (NLP) aplicado a informes radiológicos ha sido investigado principalmente en inglés. Sippon et al. [3] demostraron la viabilidad de la extracción regex de categorías BI-RADS con recall del 100% y precisión del 96,6%; Kuling et al. [4] desarrollaron BI-RADS BERT con segmentación de secciones logrando 98% de acierto en clasificación de secciones. En español, López-Úbeda et al. [5] reportaron Macro F1 de 0,74 utilizando BETO sobre corpus español peninsular para clasificación de BI-RADS. Sin embargo, la mayoría de los trabajos publicados abordan la *predicción* de la categoría BI-RADS desde el texto, no la *auditoría* de su coherencia con la conducta clínica recomendada.

Dos hechos justifican la relevancia de esta auditoría. Primero, en Chile el sistema BI-RADS no es opcional en la práctica: la Guía de Práctica Clínica AUGÉ de Cáncer de Mama del Ministerio de Salud clasifica los hallazgos mamográficos según las categorías BI-RADS y asocia cada una a una conducta —por ejemplo, los BI-RADS 4 y 5 deben derivarse como casos GES— de modo que el registro estadístico nacional y el flujo asistencial dependen de esta categorización [6]. La coherencia entre categoría y conducta es, por tanto, un requisito operativo, no solo una buena práctica. Segundo, aunque el BI-RADS estandariza el lenguaje, no elimina la variabilidad entre observadores: distintos radiólogos ante la misma imagen

alcanzan solo una concordancia moderada en la evaluación final, y esta varía según el tipo de hallazgo [7], [8]. Una herramienta que verifique de forma objetiva y reproducible la coherencia interna del informe aporta, en ese contexto, una capa de control de calidad que la interpretación humana por sí sola no garantiza. El alcance del sistema es acotado. No juzga si la categoría BI-RADS fue bien asignada –esa es la parte sujeta a variabilidad humana–, sino que, dada la categoría declarada, verifica que la recomendación sea consistente con ella, aislando así la componente auditable y objetiva del problema.

El problema específico que motiva este trabajo es distinto: dado un informe ya emitido por un radiólogo, verificar automáticamente si la categoría BI-RADS declarada y la recomendación clínica son coherentes según el estándar BI-RADS/ACR [9]. Esto se enmarca dentro de un programa más amplio de auditoría de informes mamográficos; en una línea complementaria, el autor desarrolla en paralelo, dentro de otro curso, trabajo sobre auditoría de coherencia diagnóstica.

Este artículo presenta el diseño, la implementación y la validación de un sistema local de auditoría técnica de informes mamográficos en español. La propuesta integra cuatro módulos: un extractor de categoría BI-RADS basado en reglas y robusto a variaciones tipográficas; un extractor de recomendaciones que combina normalización, reglas clínicas y similitud semántica; un motor de cotejo contra una tabla que formaliza el estándar BI-RADS/ACR; y un extractor NER basado en DistilBETO que localiza la recomendación en redacciones no anticipadas por las reglas. Todo el procesamiento ocurre localmente, sin enviar datos sensibles a servicios externos, lo que facilita el cumplimiento de normativas de protección de datos como la Ley N.º 19.628 en Chile, contexto de despliegue previsto [10]. Se optó por un motor reglado como columna vertebral en lugar de un enfoque generativo porque la tarea es esencialmente determinista: localizar una categoría declarada de forma explícita y cotejarla contra una norma fija. Además, el dominio clínico exige transparencia, reproducibilidad y auditabilidad, propiedades que un modelo generativo comprometería al introducir opacidad, comportamiento no determinista y riesgo de alucinación.

Las contribuciones principales son cuatro. Primera, la formalización computacional del estándar BI-RADS/ACR en una tabla auditable de conductas esperadas, equivalencias aceptables y niveles de severidad, aplicable a informes en español gracias a la uniformidad regional del lenguaje clínico-radiológico y pendiente de validación clínica formal. Segunda, una arquitectura donde las reglas resuelven la extracción de la categoría y el aprendizaje automático queda acotado al módulo donde la variación es semántica, con una tasa de alerta del 1,15 % sobre el corpus que mantiene baja la fatiga de alertas. Tercera, un resultado negativo medido: se entrenó y evaluó un verificador Transformer para la extracción de BI-RADS y cuatro pruebas independientes muestran que no aporta sobre la vía reglada, por lo que se retiró del pipeline y se documenta con la causa identificada. Cuarta, la evaluación empírica sobre un corpus público de 4357 informes en español [11], con validación cruzada estratificada para reportar métricas libres del sesgo de selección de checkpoint, complementada por una batería de casos sintéticos que verifica la cobertura sobre

variantes de formato ausentes del corpus y permite reproducir esa verificación sin acceso a datos clínicos.

El resto del artículo se estructura como sigue. La Sección II describe el dataset y la metodología. La Sección III presenta los resultados experimentales y su discusión. La Sección IV resume las conclusiones y delinea el trabajo futuro.

II. MATERIALES Y MÉTODOS

A. Materiales

1) *Dataset*: Se utilizó el corpus público *Mammography reporting dataset with BI-RADS system* [11], disponible en Zenodo (DOI 10.5281/zenodo.14827680). El corpus contiene 4357 informes mamográficos reales en español, anonimizados, provenientes de un centro asistencial paraguayo y emitidos entre 2019 y 2024, con etiqueta BI-RADS 0–6 y campo *Recommendations* con la conducta clínica sugerida.

La elección de este corpus responde a su disponibilidad pública y volumen sustancial, en ausencia de datasets chilenos abiertos comparables al momento de este trabajo. El objetivo del sistema es operar sobre la semántica clínico-radiológica latinoamericana en español –incluido Chile como contexto de despliegue previsto–, apoyándose en la alta uniformidad regional que induce la adopción internacional del estándar BI-RADS/ACR: los patrones lingüísticos y las categorizaciones identificadas son razonablemente extrapolables entre contextos hispanohablantes de la región. No obstante, se reconoce explícitamente como **limitación** que el corpus es de origen *paraguayo* y no chileno; por tanto, aunque el estándar compartido favorece la transferibilidad, las particularidades de redacción de cada centro o país podrían diferir. El refinamiento y la validación del sistema sobre informes mamográficos chilenos, con radiólogos locales, quedan identificados como trabajo futuro.

La distribución de etiquetas está marcadamente desbalanceada: BI-RADS 2 concentra 2635 informes (60,5%), seguido de BI-RADS 0 (966, 22,2%) y BI-RADS 1 (596, 13,7%). Las clases clínicamente críticas son minoritarias: BI-RADS 4 (52 informes, 1,2%), BI-RADS 3 (87, 2,0%), BI-RADS 5 (16, 0,4%) y BI-RADS 6 (5, 0,1%). Este desbalance motivó el uso de Macro F1 como métrica principal [12] y la aplicación de aumentación textual durante el entrenamiento del modelo Transformer.

2) *Modelo de evaluación*: Se utilizó *Transformer* y *protocolo* *DistilBETO* (dccuchile/distilbert-base-spanish-uncased) [13], una versión destilada de BETO, que a su vez adapta la arquitectura BERT [14] basada en Transformers [15], siguiendo el esquema DistilBERT [16], como modelo base, fine-tuneado sobre el corpus de entrenamiento con tres épocas, batch size 8, learning rate 2×10^{-5} , y aumentación textual sobre clases minoritarias mediante diccionarios de sinónimos clínicos. La elección de DistilBETO sobre alternativas como BETO completo o XLM-RoBERTa se justifica por su menor huella computacional (~250 MB), su entrenamiento específico en español y la disponibilidad de aceleración local mediante Metal Performance Shaders (MPS) de Apple Silicon.

Bajo un split estratificado 80/20 único, el mejor modelo alcanzó Macro F1 = 0,9386 sobre el conjunto de prueba

(872 informes). Este esquema, sin embargo, usa el mismo conjunto de prueba para seleccionar el punto de control y para la evaluación final, por lo que la métrica resultante puede quedar algo optimizada. Para obtener una evaluación libre de ese sesgo se realizó además una validación cruzada estratificada de 5 particiones [17] (con semilla fija), aplicando la aumentación textual dentro de cada partición y no de forma global, de modo que las variantes léxicas de un mismo informe no se repartieran entre entrenamiento y prueba. La métrica honesta resultante es **Macro F1 = 0,8877 ± 0,0501**, que es la del clasificador finalmente descartado. La Fig. 9 muestra el desempeño por partición: la caída del fold 4 a 0,80 refleja la sensibilidad del Macro F1 a las clases minoritarias y es la razón de reportar la validación cruzada en lugar de una partición única, cuyo resultado dependería de qué informes cayeron en el conjunto de prueba (Sección III-G). La diferencia respecto del split único (−0,0509) es la esperable al eliminar el sesgo de selección.

3) *Tabla normativa BI-RADS/ACR*: Se construyó una formalización computacional de las recomendaciones de manejo del Atlas BI-RADS de la American College of Radiology [9]. La tabla mapea cada categoría BI-RADS (0–6) a una recomendación esperada, un conjunto de equivalentes clínicamente aceptables, subcategorías de notificación suave y un nivel de severidad de alerta, a partir del estándar ACR y de la literatura clínica. Por ejemplo, BI-RADS 4 acepta como recomendación esperada *biopsia histológica*, con *derivación oncológica* como equivalente clínicamente aceptable; BI-RADS 5, en cambio, se trata de forma estricta sin equivalentes dada su criticidad clínica. El esquema de equivalencias y de severidades constituye una propuesta del autor derivada del estándar, calibrada empíricamente contra el corpus (tasa de alertas del 1,15 %) y **pendiente de validación clínica formal por radiólogos**, la cual se identifica como trabajo futuro.

Dada la uniformidad regional del lenguaje clínico-radiológico hispano y la adopción internacional del estándar BI-RADS/ACR, esta formalización resulta aplicable al corpus utilizado, con el horizonte de refinamiento futuro mediante validación específica con radiólogos chilenos sobre corpus locales.

B. Métodos

El sistema se organiza como un pipeline secuencial de cuatro módulos independientes y auditables, diseñados bajo una filosofía de *Human-on-the-Loop*: el sistema detecta inconsistencias pero no decide la conducta clínica. La Fig. 1 presenta el flujo general de datos, y la Fig. 2 detalla la función y las herramientas de cada módulo. A continuación se describe cada uno.

1) *Módulo 0: Preprocesamiento y limpieza* (*limpieza_informe.py*): Antes de cualquier extracción, el informe pasa por una capa de limpieza que elimina las líneas sin contenido clínico: el descargo legal frecuente en informes chilenos (“el presente resultado debe correlacionarse con el cuadro clínico”), la firma y validación del médico, la paginación y los datos administrativos del paciente. La limpieza opera por líneas y no por rangos, porque la extracción de texto desde un PDF puede alterar el orden y ubicar

el pie de página al inicio. El diseño es conservador: cada patrón identifica una línea inequívocamente administrativa, y una salvaguarda impide eliminar contenido cuando las coincidencias superan el 60 % de las líneas.

Esa salvaguarda protege el contenido clínico, pero entra en conflicto con la protección de datos personales. Cuando el nombre del radiólogo o un identificador quedan en la misma línea que la conclusión, algo habitual al extraer de un PDF, eliminar la línea completa se llevaría también la categoría BI-RADS. La salvaguarda lo impide, y el identificador sobrevive. Las dos protecciones se anulan entre sí.

El módulo incorpora por eso una segunda capa que redacta dentro de la línea en lugar de eliminarla, sustituyendo el fragmento identificatorio por una etiqueta genérica y conservando intacto el texto clínico. Cubre el nombre del profesional con sus tratamientos habituales, el identificador nacional en sus formatos usuales y los campos administrativos en línea. La redacción se aplica también cuando la salvaguarda revierte la eliminación, que era el caso desprotegido. Sobre el corpus completo la capa no produce falsos positivos, y el texto clínico permanece sin alterar. Con ambas capas, el sistema reduce el manejo de datos personales en concordancia con la Ley N.º 19.628.

2) *Módulo 1: Extractor de BI-RADS* (*extractor_birads.py*, *buscador_birads.py*): La tarea de este módulo es encontrar, dentro del texto libre, la categoría BI-RADS que el radiólogo asignó. Es el núcleo del sistema: define la vara contra la que el Módulo 3 mide la recomendación. Opera solo con reglas y alcanza Macro F1 = 0,9995.

La primera versión (*extractor_birads.py*) localiza el bloque de conclusión por su encabezado y busca la categoría dentro de él, aplicando una jerarquía que va del formato canónico (*BI-RADS X*) a variantes tipográficas frecuentes (*BR-X*, *Categoría X*, *BI-RADS® X*, números romanos o la categoría escrita en palabras). Sobre el corpus paraguayo esa estrategia cubre el 100 % de los informes, porque todos traen encabezado explícito (*Conclusión* en el 67,7 % y *Valoración* en el 32,3 %). Los primeros informes chilenos revelaron el límite: algunos usan *Impresión Diagnóstica*, otros carecen de encabezado, y varios mencionan la categoría más de una vez, con una referencia histórica antes de la definitiva. La dependencia del encabezado era invisible dentro del corpus de entrenamiento.

La versión en uso (*buscador_birads.py*) elimina esa dependencia con una búsqueda en cuatro fases, resumida en el Algoritmo 1. La primera recorre el informe completo y recoge todas las menciones. La segunda descarta por contexto las históricas, las comparativas, las educacionales y las negadas, atendiendo a las palabras que las preceden. La tercera pondera las restantes por su posición relativa: la categoría definitiva aparece al final del informe, y sobre el corpus la última mención se ubica en el percentil 0,85 del texto en el 100 % de los casos. La cuarta reserva un arbitraje para los empates, que sobre 4 357 informes no llegan a producirse porque el 99,9 % declara una sola mención.

Cada extracción queda etiquetada con un nivel de confianza (alta en el 98,58 % de los informes, baja en el 1,38 %) según el patrón que la produjo, de modo que los módulos




Fig. 1. Flujo general del pipeline de auditoría. El informe atraviesa los módulos en secuencia; el Módulo 4 actúa como verificación cruzada del BI-RADS, y las recomendaciones no clasificables con confianza se derivan a revisión humana.




Fig. 2. Arquitectura modular. El flujo (M0 a M3) es reglado y auditable. Un modelo DistilBETO respalda al Módulo 2 localizando la recomendación en redacciones no anticipadas. El Módulo 1 opera solo con reglas: el verificador Transformer que se probó para él se retiró tras medir que no aporta (Sección III-G).

siguientes puedan ponderarla. Si el informe presenta hallazgos radiológicos o recomendaciones pero no declara ninguna categoría, el módulo genera una alerta de omisión: un estudio con hallazgos debería concluir siempre en un BI-RADS, y su ausencia apunta a un problema de documentación que corresponde resolver a una persona y no a una imputación automática.

3) **Módulo 2: Extractor y clasificador de recomendaciones** (*extractor_recomendacion.py*): Este módulo cumple dos funciones encadenadas: primero localiza el texto de la recomendación dentro del informe y luego lo clasifica en una de ocho categorías clínicas, ordenadas de la más urgente a la menos urgente (biopsia histológica, derivación oncológica, estudio complementario de imagen, correlación ecográfica, comparación con estudios previos, control a corto plazo, control anual y criterio médico). La localización no depende de que exista un encabezado fijo de “Recomendaciones”: si el informe no lo tiene, un mecanismo de respaldo recorre el texto en busca

de frases gatillo de conducta (verbos como *se sugiere*, *amerita*, *conviene* o *derivar*), lo que permite operar sobre informes de estructura atípica, un aspecto crítico para su uso sobre datos externos.

La clasificación se apoya en un vocabulario clínico validado y en reglas que capturan la intención del texto. Incorpora varias defensas frente a la variabilidad de la redacción real: tolerancia a errores ortográficos mediante distancia de edición [18] de Damerau-Levenshtein (con umbral ≤ 1 , restringida a los verbos gatillo y nunca a cifras, para no alterar plazos ni categorías), reconocimiento de directivas expresadas como sustantivo de acción sin verbo introductorio (por ejemplo, “*control en 3 meses*”), y detección de negación al estilo NegEx para descartar menciones negadas. A esto se suma una capa de sinónimos clínicos que normaliza términos equivalentes a una forma canónica antes de aplicar las reglas: variantes de una misma técnica (*ultrasonido*, *US* y *ecotomografía* para ecografía; *RMN* y *MRI* para resonancia), abreviaturas de biopsia (*BACAF*, *PAAF*,

Algoritmo 1 Búsqueda híbrida de la categoría BI-RADS**Entrada:** Informe T como texto plano**Salida:** Categoría c con su nivel de confianza, o alerta

```

1:  $M \leftarrow$  todas las menciones de BI-RADS en  $T$   $\triangleright$  Fase 1
2: if  $M = \emptyset$  then
3:   if  $T$  contiene hallazgos o recomendaciones then
4:     return alerta de omisión  $\triangleright$  no se imputa categoría
5:   else
6:     return sin categoría
7:   end if
8: end if
9: for all  $m \in M$  do  $\triangleright$  Fase 2: filtrado contextual
10:    $v \leftarrow$  ventana previa a  $m$ 
11:   if  $v$  indica mención histórica, comparativa, educacional
      o negada then
12:     marcar  $m$  como descartada
13:   end if
14: end for
15:  $M' \leftarrow \{m \in M : m \text{ no descartada}\}$ 
16: if  $M' = \emptyset$  then
17:    $M' \leftarrow M$   $\triangleright$  repliegue: ninguna sobrevive al filtro
18: end if
19: for all  $m \in M'$  do  $\triangleright$  Fase 3: ponderación posicional
20:    $p(m) \leftarrow \text{pos}(m)/|T|$ 
21:    $w(m) \leftarrow \alpha \cdot p(m) + \beta \cdot \text{especificidad}(m)$ 
22: end for
23:  $C \leftarrow \arg \max_{m \in M'} w(m)$ 
24: if  $|C| > 1$  then  $\triangleright$  Fase 4: arbitraje solo si hay empate
25:    $C \leftarrow$  desempate por posición más tardía
26: end if
27: return categoría de  $C$  con confianza según el patrón que
    la produjo

```

core biopsy) y equivalencias de conducta (*seguimiento* por control, *en un año* por anual). Los sinónimos se anclaron con contexto para evitar reescrituras erróneas y se excluyeron deliberadamente términos clínicamente ambiguos. Cuando ninguna regla clasifica el texto con confianza, la recomendación se marca como ambigua y se deriva a revisión, en lugar de forzar una categoría que podría ser errónea.

a) *Extractor NER de respaldo* (*extractor_ner.py*): La localización por reglas es transparente y rápida, pero exige anticipar cada forma de redacción. Para las redacciones no vistas se incorporó un extractor neuronal que actúa como vía de respaldo: un modelo DistilBETO afinado para reconocimiento de entidades (NER) que localiza el fragmento de recomendación dentro del informe. A diferencia de las reglas, el modelo aprende el contexto de lo que es una recomendación y generaliza a formas que no estaban en el vocabulario. El etiquetado sigue el esquema BIO [19], que marca el inicio, el interior y el exterior de cada entidad. Su entrenamiento no requirió etiquetado manual: como la recomendación aparece textualmente dentro del informe, las etiquetas por token se derivaron automáticamente alineando la columna de recomendación del corpus. La arquitectura resultante es híbrida y sigue la misma lógica que el módulo de BI-RADS: las reglas son la vía primaria y, cuando no localizan

la recomendación, el NER la extrae; si ninguno lo logra con confianza, el caso se deriva a revisión humana. Una salvaguarda de posprocesamiento toma únicamente el primer fragmento contiguo etiquetado, de modo que etiquetas dispersas ante elementos no vistos (firmas, encabezados) no contaminen la extracción.

4) *Módulo 3: Motor de cotejo BI-RADS/ACR* (*cotejo_acr.py*): Este módulo es el núcleo de la auditoría. Recibe la categoría BI-RADS extraída y la recomendación ya clasificada, y decide si ambas son coherentes según el estándar ACR. El módulo no evalúa si el BI-RADS está bien asignado ni juzga los hallazgos. Toma el BI-RADS tal como viene y verifica únicamente que la recomendación sea consistente con él. El BI-RADS funciona, entonces, como la vara contra la que se mide la recomendación, no como algo a medir.

Para ello, cada categoría BI-RADS tiene en la tabla una conducta esperada según la norma, una lista de equivalentes aceptables, otra de equivalentes que ameritan una notificación suave, y un conjunto de conductas que se marcan para revisión. El motor recorre estas opciones en orden de prioridad clínica, como ilustra la Fig. 3, y se detiene en la primera que aplica:

- 1) Si la recomendación coincide con la esperada, es coherente y no se emite alerta.
- 2) Si no coincide pero figura entre los equivalentes aceptables (por ejemplo, la derivación oncológica en un BI-RADS 5, dado que el especialista ordenará la biopsia), también es coherente.
- 3) Si figura entre los equivalentes que ameritan mención, es una incoherencia leve: se emite una alerta de baja prioridad.
- 4) Si es una conducta marcada para revisión (por ejemplo, una acción invasiva sobre un hallazgo benigno), se genera una alerta de revisión.
- 5) Si la recomendación es más cauta que la esperada y no cae en el caso anterior, se acepta con precaución, sin alerta, porque exceder la cautela rara vez es riesgoso.
- 6) Si nada de lo anterior aplica, la recomendación se queda corta frente a lo que pide la norma, y se genera una alerta cuya gravedad se gradúa según el impacto en salud.

El principio que ordena todo es clínico: quedarse corto, es decir, recomendar una conducta menos urgente de la necesaria, es el escenario peligroso, porque puede retrasar el diagnóstico de un cáncer. Pasarse de cauto casi nunca lo es. Por eso el sistema es tolerante hacia la precaución de más y estricto hacia la de menos.

Toda la lógica clínica reside en la tabla y no en el código, de modo que un especialista puede leerla y corregirla sin tocar el programa. Cada salida, además, registra la regla exacta que se aplicó, lo que hace auditable no solo la alerta sino su justificación.

a) *Graduación de la alerta por impacto en salud*: El Algoritmo 2 resume la lógica completa. La auditoría de coherencia es binaria: una recomendación es coherente o no lo es. Es coherente cuando coincide con la esperada, es un equivalente aceptable, o es más cauta que la mínima esperada, ya que un exceso de precaución –por ejemplo, biopsiar un BI-RADS 3– es clínicamente válido. Es incoherente cuando




Fig. 3. Cómo el sistema decide sobre un informe. En la Etapa 1 verifica si pudo entender el informe; si no, lo deriva a revisión por extracción. En la Etapa 2 la auditoría es binaria: la recomendación es coherente (coincide, equivale o es más cauta) o incoherente. Toda incoherencia genera alerta, graduada de baja a crítica según su impacto en salud.

la recomendación se queda corta frente a la norma. Toda incoherencia genera una alerta; lo que varía es su severidad, no el hecho de constituir o no un problema. Así, la palabra alerta conserva su significado, y su gravedad, desde una incoherencia leve y sin riesgo hasta una crítica, comunica cuánto importa.

La severidad no proviene de casos particulares del corpus, sino de una regla general que combina dos factores medibles para cualquier informe: la criticidad del BI-RADS, que la norma ACR fija de antemano (BI-RADS 4 y 5 conllevan sospecha de malignidad; 0 y 6 son intermedios; 1, 2 y 3 son de bajo riesgo), y cuánto se aparta la recomendación de la conducta esperada dentro de la jerarquía de urgencia. La regla central, validada con criterio clínico, es que una sospecha de malignidad (BI-RADS 4 o 5) cuya recomendación no incluya biopsia ni derivación se clasifica siempre como crítica, pues cualquier conducta que no confirme el diagnóstico implica un riesgo de retraso. Una incoherencia leve, en cambio, corresponde a un desvío menor en una categoría de bajo riesgo, sin consecuencias para la paciente. La Tabla I resume los desenlaces y su distribución en el corpus.

A este esquema se suma un desenlace de naturaleza distinta. Cuando el sistema no logra extraer ni clasificar la recomendación, no puede juzgar la coherencia, de modo que no afirma que el caso sea correcto ni inventa una inconsistencia: lo marca como revisión por extracción y lo deriva a un humano. Esta abstención es deliberada. Distingue con honestidad los casos en que el sistema entendió el informe y halló un desacuerdo clínico de aquellos en que sencillamente no pudo leerlo, quizá por un formato atípico.

La severidad de esa revisión depende de la categoría. Cuando el BI-RADS es 4, 5 o 6, la ausencia de una recomendación clasificable se marca como crítica. La norma ACR exige una conducta explícita para esas categorías, de modo que su ausencia en el informe no es un problema técnico de lectura sino un vacío de documentación en el escenario de mayor riesgo. Es la contraparte de la alerta de omisión del Módulo 1: allí falta la categoría, aquí falta la conducta. Para el resto de las categorías la revisión se marca con prioridad media.

TABLE I

DESENLACES DEL COTEJO Y SU DISTRIBUCIÓN EN EL CORPUS (4 357 INFORMES). LA AUDITORÍA ES BINARIA (COHERENTE O INCOHERENTE); LA INCOHERENCIA SE GRADÚA DE BAJA A CRÍTICA. EN TOTAL, 50 INFORMES (1,1 %) RESULTAN INCOHERENTES.

Desenlace	Situación	Casos
Coherente	Coincide, equivale o es más cauta (sin alerta)	4 299
Incoh. crítica	Sospecha (BI-RADS 4/5) sin acción diagnóstica	19
Incoh. alta	Desvío relevante en categoría intermedia	18
Incoh. media	Inconsistencia a revisar, sin urgencia	9
Incoh. baja	Desvío menor sin riesgo para la paciente	4
Revisión ext.	No se pudo extraer o clasificar la recomendación	8

5) *Módulo 4: verificador del BI-RADS, diseñado y retirado* (*verificador_birads_ml.py*): Este módulo se planteó para obtener la categoría por dos vías y contrastarlas: la extracción por reglas del Módulo 1 y un DistilBETO que relea el mismo texto. Priorizaba la regla, bajo el supuesto de que la categoría escrita por el radiólogo es la referencia, y reservaba la voz del modelo para los casos de baja confianza, distinguiendo cinco estados según el acuerdo entre ambas (Fig. 10). El modelo lee una ventana local alrededor de la mención candidata para que ambas vías trabajen sobre el mismo fragmento.

Se implementó y se evaluó por completo, y la evaluación llevó a retirarlo: la Sección III-G detalla las mediciones. El Módulo 1 opera solo con reglas (*usar_verificador_ml=False*). El código se conserva en el repositorio junto con su evaluación, dado que el resultado negativo delimita el rol de la IA en el sistema.

C. Arquitectura del pipeline

Un informe textual ingresa al pipeline y atraviesa los cuatro módulos en secuencia. El programa opera así: primero recibe el texto del informe; el Módulo 1 localiza y extrae la categoría BI-RADS declarada; el Módulo 2 localiza el texto de la recomendación, primero por su encabezado y, si el informe no lo tiene, mediante un *fallback* que recorre

Algoritmo 2 Cotejo de coherencia BI-RADS/ACR

Entrada: Categoría b , recomendación clasificada r , tabla normativa $\mathcal{T}$

Salida: Estado, severidad y regla aplicada

```

1: if  $r$  es nula o ambigua then  $\triangleright$  abstención: no se juzga coherencia
2:   if  $b \in \{4, 5, 6\}$  then
3:     return REVISIÓN, severidad crítica
       la norma exige conducta explícita para estas categorías
4:   else
5:     return REVISIÓN, severidad media
6:   end if
7: end if
8:  $e \leftarrow \mathcal{T}[b].esperada$ 
9: if  $r = e$  then
10:  return COHERENTE
11: else if  $r \in \mathcal{T}[b].equivalentes$  then
12:  return COHERENTE_EQUIVALENTE
13: else if  $urgencia(r) > urgencia(e)$  then
14:  return COHERENTE_CON_PRECAUCIÓN
       un exceso de cautela es clínicamente válido
15: end if
16:  $d \leftarrow urgencia(e) - urgencia(r)$   $\triangleright$  desvío en la jerarquía
17: if  $b \in \{4, 5\}$  y  $r \notin \{\text{biopsia, derivación}\}$  then
18:  return INCOHERENTE, severidad crítica
       sospecha sin acción diagnóstica
19: end if
20: severidad  $\leftarrow$  función de criticidad( $b$ ) y de  $d$ 
21: return INCOHERENTE, severidad

```

el texto buscando frases gatillo de conducta, de modo que la extracción no dependa de una estructura fija, y luego lo clasifica en una de ocho categorías clínicas; el Módulo 3 consulta la tabla normativa BI-RADS/ACR y contrasta la recomendación clasificada con la esperada para esa categoría, emitiendo un estado de coherencia y, si corresponde, una alerta con su severidad. Cuando el Módulo 2 no logra clasificar con confianza, la recomendación se marca como *ambigua* y se deriva a revisión humana en vez de forzar una categoría.

El pipeline produce una salida estructurada y trazable, con la categoría BI-RADS extraída y su nivel de confianza, la recomendación clasificada y la esperada, el estado del cotejo, un mensaje explicativo y la regla aplicada. Cada uno de estos campos queda accesible para auditoría, en coherencia con la filosofía Human-on-the-Loop.

D. Métricas de evaluación

La evaluación se realizó sobre el corpus completo (4357 informes) utilizando: (i) *accuracy* y *Macro F1* para la extracción de BI-RADS y para la predicción del modelo ML, reportadas bajo split único estratificado y bajo validación cruzada 5-fold estratificada; (ii) *cobertura* (% de informes con recomendación clasificada) para el módulo 2; (iii) *tasa de alertas clínicas* (% del corpus que genera alerta) como indicador de fatiga de alertas; (iv) *cobertura de variantes de formato* sobre la batería de casos sintéticos. Para el módulo 4, evaluado y luego retirado,



Fig. 4. Interfaz de auditoría sobre dos informes de ejemplo. A la izquierda, una alerta crítica (BI-RADS 5 con control anual); a la derecha, un caso coherente sin alerta (BI-RADS 2 con control anual). Cada resultado muestra el BI-RADS, la recomendación detectada y la esperada, junto con un mensaje explicativo.

se reportan además la caída bajo ablación y la comparación contra una línea base trivial, que son las mediciones que motivaron su descarte.

E. Implementación

El sistema se implementó en Python 3.9, con transformers 4.57.6, torch 2.8.0, y scikit-learn 1.6.1. La aceleración por hardware utilizó Metal Performance Shaders (MPS) de Apple Silicon. El código es público bajo el repositorio proyecto-ia-mamografia¹, organizado en módulos src/ con tests inline y notebooks de exploración notebooks/05 a 10. La reproducibilidad está garantizada mediante requirements.txt y semillas fijas (numpy, torch, random) en los splits estratificados y en cada fold de la validación cruzada.

F. Interfaz de visualización

Para acercar el sistema al usuario clínico se desarrolló una interfaz web ligera (Fig. 4). El usuario pega el texto de un informe y obtiene, de inmediato, el desenlace del cotejo comunicado en términos simples: la categoría BI-RADS extraída, la recomendación detectada, la esperada por el estándar, y un distintivo de color que resume el resultado: coherente, incoherente (con su severidad) o revisión por extracción. La interfaz privilegia la legibilidad para un profesional no técnico: muestra un mensaje explicativo en lenguaje clínico, y ofrece la trazabilidad de la regla aplicada en un panel desplegable para quien desee auditar la decisión. Toda la ejecución ocurre localmente, en coherencia con los requisitos de privacidad del sistema.

III. RESULTADOS Y DISCUSIÓN

A. Métricas de desempeño

La Tabla II resume el desempeño de los módulos sobre el corpus completo. La extracción de BI-RADS por reglas alcanzó

¹<https://github.com/SebasDCIS/proyecto-ia-mamografia>

TABLE II
DESEMPEÑO POR MÓDULO SOBRE EL CORPUS COMPLETO (4 357 INFORMES).

Módulo	Métrica	Valor
Extracción BI-RADS (reglas)	Macro F1 / cobertura	0,9995 / 100 %
Clasificación de la recomendación	Cobertura	99,82 %
Extractor NER	F1 de span (test dedup.)	0,9991
Cotejo BI-RADS/ACR	Tasa de incoherencias	1,15 %
Verificador DistilBETO (descartado)	Macro F1 (CV 5-fold)	0,8877 $\pm$ 0,0501

TABLE III
RESULTADOS POR FOLD DE LA VALIDACIÓN CRUZADA ESTRATIFICADA 5-FOLD DE DISTILBETO CON AUMENTACIÓN APLICADA POR FOLD.

Fold	Accuracy	Macro F1	Weighted F1
1	0,9851	0,9113	0,9849
2	0,9874	0,9262	0,9875
3	0,9874	0,8842	0,9872
4	0,9805	0,8024	0,9800
5	0,9816	0,9144	0,9817
Media	0,9844	0,8877	0,9852
σ	0,0032	0,0501	0,0032

Macro F1 = 0,9995 (exactitud 99,9%) con cobertura total, confirmando que la localización de la categoría declarada es una tarea esencialmente reglada. El extractor de recomendaciones clasificó el 99,8% del corpus mediante reglas clínicas con confianza alta. El extractor NER de respaldo alcanzó un F1 a nivel de span de 0,999 en el conjunto de prueba deduplicado; como se discute más adelante, esta cifra refleja la homogeneidad del corpus más que la generalización, por lo que su valor real se evaluó con informes externos. El motor de cotejo BI-RADS/ACR generó alerta clínica en solo el 1,15% de los informes, un nivel bajo de fatiga de alertas.

Para el clasificador Transformer, la Tabla III detalla los resultados por fold de la validación cruzada. Su Macro F1 es $0,8877 \pm 0,0501$, por encima del mejor baseline clásico (LinearSVC, $0,7369 \pm 0,0703$; Fig. 5). Ese resultado motivó en su momento adoptarlo, y la Sección III-G explica por qué se retiró después.

B. Comparación con trabajos previos

Los trabajos citados en la Sección I permiten situar estos resultados, con una precaución: no todos abordan la misma tarea.

Sippo *et al.* [3] extraen la categoría BI-RADS de informes en inglés mediante expresiones regulares y reportan 100 % de *recall* y 96,6 % de precisión. Es la referencia más directa, porque resuelve la misma tarea de localizar un dato declarado. El extractor descrito aquí alcanza Macro F1 = 0,9995 sobre 4 357 informes en español. La comparación tiene sentido en cuanto al enfoque, aunque los corpus difieren en idioma, origen y estructura, de modo que las cifras no son intercambiables.

López-Úbeda *et al.* [5] reportan Macro F1 = 0,74 con BETO sobre un corpus español peninsular. Esa cifra corresponde a




Fig. 5. Macro F1 bajo validación cruzada 5-fold. DistilBETO supera al baseline LinearSVC con margen robusto. La línea punteada marca el Macro F1 del split único (0,939), optimista por el sesgo de selección de checkpoint.

predecir la categoría a partir del texto, no a extraer la que el radiólogo declaró, y por eso no debe contrastarse con el 0,9995 de la vía reglada. El experimento equivalente en este trabajo es la predicción del BI-RADS desde los hallazgos, que alcanza Macro F1 = 0,624 fuera de fold. La diferencia entre ambos valores se explica por la disponibilidad de datos en las clases críticas: en el corpus utilizado, las categorías 4, 5 y 6 reúnen 52, 16 y 5 ejemplos respectivamente.

Confundir esas dos tareas es el error que este trabajo procura evitar. Una regla que localiza una cadena declarada y un modelo que infiere una categoría desde los hallazgos resuelven problemas distintos, y sus métricas no son comparables aunque compartan el nombre de la etiqueta. La auditoría de coherencia requiere la primera, no la segunda.

Kuling *et al.* [4] atacan un problema adyacente, la segmentación de secciones del informe, con 98 % de acierto. Ese componente es análogo al Módulo 0 de este sistema, aunque aquí se resuelve por reglas y no por un modelo, y sin métrica propia porque su efecto se observa aguas abajo.

La diferencia de fondo con los tres trabajos es de objetivo. Todos abordan la extracción o clasificación de la categoría BI-RADS; ninguno coteja esa categoría contra la recomendación clínica para detectar incoherencias, que es el aporte de este sistema y la razón por la que la tabla normativa del Módulo 3 no tiene equivalente en la literatura revisada.

C. Estudio descriptivo de los datos

La Fig. 6 muestra la marcada asimetría de clases del corpus: BI-RADS 2 concentra el 60,5% de los informes, mientras que las categorías clínicamente críticas son minoritarias (BI-RADS 4, 5 y 6 suman apenas el 1,7%). Esta distribución justifica dos decisiones metodológicas centrales: el uso de Macro F1 –que pondera por igual todas las clases– en lugar de *accuracy*, que quedaría dominada por la clase mayoritaria; y la aplicación de aumentación textual dirigida a las clases minoritarias durante el entrenamiento del Transformer.

La Fig. 7 presenta la distribución de las recomendaciones clasificadas por el módulo 2. Predominan la correlación ecográfica (45,9%) y el control anual (29,6%), coherente con la alta prevalencia de BI-RADS 0 y 2; la escasez de




Fig. 6. Distribución de categorías BI-RADS en el corpus (escala logarítmica). El fuerte desbalance –BI-RADS 2 concentra el 60,5%; las clases críticas 4/5/6 el 1,7%– motiva el uso de Macro F1 y la aumentación de clases minoritarias.




Fig. 7. Distribución de las categorías de recomendación clasificadas por el módulo 2 sobre el corpus.

recomendaciones de biopsia (1,4%) refleja la baja frecuencia de las categorías sospechosas y refuerza el desafío de clasificar correctamente dichas clases.

D. Análisis de resultados del pipeline

1) *El verificador Transformer: por qué se retiró:* El Módulo 4 se diseñó como verificación cruzada de la extracción reglada y se retiró tras medirlo. Dos resultados lo determinan.

El estudio de ablación (Fig. 8) enmascara la mención textual del número BI-RADS y reevalúa: el Macro F1 cae de 0,9386 a 0,5438, un 42 % menos. El modelo lee la categoría declarada en lugar de deducirla de los hallazgos.

La comparación contra una línea base trivial cierra el punto. En inferencia el modelo recibe una ventana de 250 caracteres centrada en la mención que la regla seleccionó. Sobre esa misma ventana, una expresión regular de una línea alcanza 99,82 % de exactitud y DistilBETO 99,78 %. Ambas vías leen la misma cadena, de modo que el contraste entre ellas no constituye una segunda opinión independiente sino una relectura del mismo dato.

La causa de fondo es que leer una categoría declarada no admite discrepancia informativa: BI-RADS 4 no es ambiguo. Un segundo lector aportaría si dedujera la categoría desde




Fig. 8. Estudio de ablación. Al enmascarar el número BI-RADS del texto, el Macro F1 del Transformer cae un 42% (0,939 → 0,544), evidenciando que el modelo lee la categoría declarada más que deducirla de los hallazgos.




Fig. 9. Macro F1 por fold en la validación cruzada. La caída del fold 4 (0,80) refleja la sensibilidad de la métrica macro a las clases minoritarias y justifica reportar la CV en lugar de un split único.

los hallazgos, tarea que se evaluó por separado y alcanza Macro F1 = 0,624 fuera de fold, insuficiente en las clases críticas. El Módulo 1 opera en consecuencia solo con reglas, con Macro F1 = 0,9995. La IA se mantiene donde la evaluación respalda su uso, el extractor NER del Módulo 2, cuya tarea presenta variación semántica y no tipográfica: los formatos de un número se enumeran en una tabla; las redacciones de una recomendación clínica, no.

La Fig. 10 resume la salida que producía el verificador: el 96,4% de los informes resultó *confirmado* (regex de alta confianza y ML concordante), un 3,0% obtuvo *confirmación cruzada* (regex de menor confianza respaldada por el ML), un 0,6% quedó sin confirmación del ML (prevaleciendo la regex), y solo un 0,07% constituyó una discrepancia real que amerita revisión manual. Esa concordancia casi total no mide acierto sino redundancia: el modelo relee la cadena que la regla ya extrajo, de modo que coincidir es el resultado esperable.

E. Extractor NER de recomendaciones: desempeño y generalización

El extractor neuronal se entrenó sobre el corpus con etiquetas derivadas automáticamente, previa deduplicación robusta para evitar fuga de información entre particiones [20]. La Tabla IV detalla los hiperparámetros de este entrenamiento




Fig. 10. Distribución de estados del verificador Transformer que se diseñó y luego se retiró. El 96,4 % de los informes queda confirmado y solo el 0,07 % produce una discrepancia real. Esa concordancia casi total es consecuencia de que el modelo relea la misma cadena que la regla ya extrajo, y es una de las cuatro evidencias que motivaron el descarte (Sección III-G).

TABLE IV
HIPERPARÁMETROS DE LOS DOS ENTRENAMIENTOS AFINADOS SOBRE DISTILBETO.

Hiperparámetro	Verificador BI-RADS	Extractor NER
Tarea	clasificación sec.	etiquetado (NER)
Modelo base	DistilBETO	DistilBETO
Épocas	3	6 (early stop.)
Batch size	8	16
Learning rate	2×10^{-5}	3×10^{-5}
Weight decay	0,01	0,01
Warmup ratio	sin configurar (0)	0,1
Long. máx. (subtokens)	256	384
Selección de modelo	CV 5-fold	mejor F1 val.
Partición	CV estratíf.	70/15/15 estratíf.
Semilla	fija	42

y los del verificador que se descartó, ambos afinados a partir de DistilBETO. Para el NER se cuidó especialmente evitar el sobreajuste y la fuga: el conjunto se separó en entrenamiento, validación y prueba antes de tokenizar; se aplicó *early stopping* guiado solo por la validación; y la longitud máxima de secuencia se fijó en 384 subtokens para no truncar la recomendación, que suele ubicarse al final del informe.

En el conjunto de prueba deduplicado alcanzó un F1 a nivel de span de 0,999 (Fig. 11). Esta cifra debe leerse con cautela. El corpus es muy homogéneo: la recomendación aparece siempre al final del informe y, tras normalizar el texto, existen apenas 221 recomendaciones distintas (la más frecuente se repite 784 veces), de modo que el valor mide la facilidad del corpus y no la capacidad de generalizar. La evaluación relevante se hizo entonces sobre informes chilenos externos, de formato no visto. Allí el modelo extrajo correctamente redacciones que las reglas no cubrían, como “*complementar examen con ecografía*”, y cuando el informe no traía recomendación explícita no extrajo nada, sin inventar texto. El desempeño dentro del corpus y el comportamiento en datos externos difieren, y esa diferencia orienta la mejora de fondo hacia un corpus del contexto de despliegue. Mientras tanto, el NER cumple un rol acotado de respaldo, con las reglas transparentes como vía primaria.




Fig. 11. Entrenamiento y desempeño del extractor NER. (a) La pérdida de validación descende y el F1 se estabiliza en pocas épocas; el *early stopping* carga el mejor modelo. (b) Métricas a nivel de span en el conjunto de prueba deduplicado. Los valores cercanos a la unidad reflejan la homogeneidad del corpus; la evaluación de generalización se hizo con informes externos.

TABLE V
PRUEBA DE ESTRÉS SOBRE 565 INFORMES DE PRUEBA: F1 DE SPAN EXACTO.

Condición	Regla	NER
Control	1,0000	1,0000
Sin encabezado	0,9460	1,0000
Verbo fuera de la lista	1,0000	0,9929
Sin encabezado y verbo nuevo	0,5314	0,9956

1) *Prueba de estrés: redacciones no anticipadas*: El F1 de 0,9991 mide el NER dentro del corpus, pero su rol es servir de respaldo ante redacciones que las reglas no anticiparon, y ese rol se ejerce fuera del corpus. La métrica del corpus no lo evalúa. De hecho, medido dentro, una expresión regular que localiza el último verbo gatillo y marca hasta el final del informe alcanza $F1 = 0,9991$ frente al 1,0000 del NER: sobre este corpus el modelo no aporta, porque el 98,1 % de las recomendaciones comienza con la misma fórmula y todas ocupan la posición final.

La evidencia a favor del NER son los tres informes chilenos donde las reglas fallaron, lo que es poco. Para medir su rol sobre una muestra mayor se perturbó el conjunto de prueba de modo que reprodujera la brecha: se eliminó el encabezado RECOMENDACIONES y se substituyó el verbo gatillo por formas verificadas como ausentes de `_FRASES_GATILLO_RECOMENDACION`, la lista cerrada del módulo. Los reemplazos se comprobaron uno a uno contra esa expresión regular y todos tienen dos tokens, de modo que el span conserva su posición y su largo. La regla evaluada es el módulo de producción en su segunda vía, la que opera cuando no existe columna de recomendaciones, es decir la que se ejecuta ante un PDF.

La Tabla V muestra que la regla dispone de dos señales independientes y se sostiene mientras conserve una de ellas: sin encabezado alcanza 0,9460 porque el verbo la rescata, y con un verbo desconocido alcanza 1,0000 porque el encabezado la rescata. Al retirar ambas queda en 0,5314. El NER no depende de ninguna de las dos y se mantiene entre 0,9929 y 1,0000 en las cuatro condiciones.

La última fila es la que corresponde al caso chileno: un informe sin encabezado explícito y con una redacción no prevista. Ahí la regla pierde cerca de la mitad de las recomendaciones y el NER conserva 0,9956. Ese resultado

TABLE VI
BATERÍA DE CASOS SINTÉTICOS: VARIANTES CUBIERTAS.

Grupo	Variantes
Escritura del BI-RADS	Arábigo; numeral romano (<i>Birads -us III</i>); modalidad antepuesta (<i>US BIRADS 1</i>) y pospuesta (<i>Birads 2 US</i>); error de tipeo (<i>bi-radas</i>)
Estructura	<i>Impresión mamográfica</i> en lugar de <i>Conclusión</i> ; sin encabezado; descargo legal reubicado al inicio; mención histórica previa a la definitiva
Recomendación	Forma verbal (<i>controlar por control</i>); sinónimos de técnica (<i>ultrasonido</i>)
Comportamiento seguro	Hallazgos sin categoría; sospecha sin conducta declarada; incoherencia crítica
Privacidad	Nombre e identificador adheridos al texto clínico

delimita el aporte del modelo: no mejora la extracción en el corpus, donde una regla trivial lo iguala, sino que sostiene el desempeño cuando las señales que las reglas presuponen no están.

El contraste con el verificador de BI-RADS resulta explícito bajo la misma prueba. Al enmascarar la señal de la que depende cada modelo, el verificador cae de 0,939 a 0,544 mientras que el NER pasa de 1,000 a 0,9956. El verificador disponía de una sola señal, el número declarado, y sin ella no le quedaba nada que leer. El NER aprendió a reconocer qué constituye una recomendación clínica en lugar de memorizar los términos que la introducen.

Este experimento es sintético: opera sobre el corpus paraguayo perturbado y no sobre informes chilenos reales. Mide el rol que el componente cumple, no su desempeño en Chile. La validación con un corpus chileno anotado sigue siendo la limitación de fondo del trabajo.

F. Cobertura ante variantes de formato

El corpus de entrenamiento es homogéneo. Todos sus informes traen encabezado de conclusión, ninguno escribe la categoría con numerales romanos, la recomendación ocupa siempre la posición final y los datos del paciente ya vienen retirados. Esa uniformidad permite que un sistema sostenga supuestos sin que nada los ponga a prueba, y fue el origen de varias fragilidades descritas en las secciones anteriores.

Para verificar la cobertura sobre variantes que el corpus no contiene se construyó una batería de 16 casos de prueba sintéticos. Son informes ficticios, con nombres, identificadores y fechas inventados, que reproducen formas de redacción y estructura documentadas en la práctica clínica local. Cada caso declara el resultado esperado, de modo que la batería funciona también como prueba de regresión y puede ejecutarse sin acceso a datos clínicos.

El sistema resuelve correctamente los 16 casos en las cuatro dimensiones evaluadas: categoría extraída, recomendación clasificada, estado del cotejo y ausencia de identificadores tras la limpieza. La Tabla VI resume los grupos cubiertos.

Dos resultados merecen comentario. El primero es que el corpus no contiene ni un solo numeral romano, mientras que la práctica local sí los emplea. El soporte para esa variante se programó como cobertura preventiva, sin disponer de un

ejemplo que lo justificara, y la batería lo verifica. Un modelo entrenado sobre el corpus no podría cubrirla, porque nunca la vio: es un argumento concreto a favor de las reglas en una tarea donde la variación es tipográfica y enumerable.

El segundo es el caso de una categoría de alta sospecha que no declara ninguna conducta. Ese escenario motivó el escalamiento de severidad descrito en el Módulo 3. Sin él, la ausencia de recomendación en un BI-RADS 5 se habría tratado igual que en un BI-RADS 1.

La batería verifica cobertura de formatos, no desempeño poblacional. Los casos son sintéticos y contruados para cubrir variantes conocidas, de modo que no sustituyen la validación con un corpus clínico anotado del contexto de despliegue, que sigue siendo la limitación de fondo del trabajo. Lo que sí permiten es distinguir entre un sistema que funciona sobre su corpus y uno que funciona sobre las formas en que los informes se escriben en la práctica.

G. Verificación de las decisiones de diseño

La elección de un núcleo reglado se sometió a verificación empírica en lugar de asumirse. Se diseñó una serie de experimentos controlados para contrastar, sobre la misma tarea y corpus, el enfoque reglado frente a alternativas basadas en aprendizaje automático, con el fin de fundamentar la arquitectura final en evidencia.

Primero, cuatro pruebas independientes sobre el verificador Transformer (ablación, frecuencia de intervención, comparación contra una línea base trivial y recuperación de formatos no vistos) mostraron que no aporta sobre la vía reglada, lo que llevó a retirarlo del pipeline. Segundo, se verificó el límite de una línea de *predicción* del BI-RADS desde los hallazgos, cuyo desempeño queda determinado por la disponibilidad de datos en las clases clínicamente críticas –una propiedad del corpus, no de la técnica–, lo que orienta el trabajo futuro hacia la recolección de datos. Tercero, se evaluaron enfoques de *embeddings* semánticos como refuerzo de la clasificación de recomendaciones; la evaluación mostró que el enfoque reglado captura mejor la jerarquía clínica de las recomendaciones compuestas, consolidando su elección como método principal.

La convergencia de estos experimentos aporta un respaldo sólido a la arquitectura: para una tarea de granularidad clínica fina, sobre un corpus con fuerte desbalance, y en un dominio que exige transparencia, reproducibilidad, auditabilidad y ejecución local, el enfoque reglado es la opción más adecuada, y el aprendizaje automático se reserva para roles acotados y verificados. Esta verificación metodológica constituye una de las contribuciones del trabajo.

H. Limitaciones

El trabajo tiene cuatro limitaciones que conviene declarar de forma explícita.

Origen del corpus. Los 4357 informes son de origen paraguayo, mientras que el contexto de despliegue previsto es chileno. El corpus es además homogéneo: todos sus informes traen encabezado de conclusión, ninguno escribe la categoría con numerales romanos y los datos del paciente ya vienen retirados. Esa uniformidad permite sostener supuestos

que la práctica local no respeta, y fue el origen de varias fragilidades corregidas durante el desarrollo. La batería de casos sintéticos de la Sección III-F verifica cobertura de formatos, no desempeño poblacional, y no sustituye la validación con un corpus clínico anotado del contexto de despliegue.

Validación clínica de la tabla normativa. La formalización del estándar BI-RADS/ACR, con sus conductas esperadas, equivalencias aceptables y niveles de severidad, se construyó a partir del Atlas ACR y de la Guía AUGE, y se calibró contra el corpus. No ha sido validada formalmente por un panel de radiólogos. Las equivalencias aceptables y los umbrales de severidad son decisiones de diseño fundamentadas, no consenso clínico establecido.

Alcance de la auditoría. El sistema verifica la coherencia entre la categoría declarada y la recomendación. No evalúa si esa categoría fue bien asignada a partir de las imágenes, tarea que exigiría deducirla de los hallazgos. El experimento correspondiente alcanza Macro F1 = 0,624 fuera de fold, insuficiente en las clases críticas, de modo que esa capacidad queda fuera del sistema y no se reclama.

Ausencia de patrón oro para la recomendación. La clasificación de la recomendación en categorías clínicas se evaluó por cobertura y por concordancia entre vías, no contra anotaciones de referencia elaboradas por especialistas. Sin ese patrón oro, las métricas indican consistencia interna del sistema, no exactitud clínica.

Estas limitaciones acotan las afirmaciones del trabajo pero no invalidan su núcleo: la extracción de la categoría declarada, que es la vara del cotejo, se mide contra la etiqueta del corpus y alcanza Macro F1 = 0,9995.

IV. CONCLUSIONES

Este trabajo presentó un sistema local e interpretable de auditoría técnica de informes mamográficos en español que contrasta la categoría BI-RADS declarada con la recomendación clínica bajo el estándar BI-RADS/ACR. La conclusión central es metodológica: aunque el proyecto se planteó con la intención de emplear modelos de aprendizaje automático y entrenamiento como núcleo del sistema, una serie de experimentos verificó que, para esta tarea y este dominio, el enfoque reglado es superior. Las conclusiones específicas son: (i) el sistema realiza la auditoría de coherencia con una extracción reglada de alta exactitud (99,9%) como columna vertebral auditable, robustecida para operar sobre informes de estructura variable; (ii) la formalización computacional de la tabla normativa BI-RADS/ACR permite detectar inconsistencias con una tasa de alerta del 1,15 % sobre el corpus, de la que 24 casos alcanzan severidad crítica, y un 0,18 % adicional que el sistema no logra leer y deriva a revisión, lo que mantiene baja la fatiga de alertas; (iii) los experimentos con modelos –clasificación, predicción desde hallazgos y *embeddings* semánticos– resultaron inferiores o quedaron limitados por los datos, lo que confirma con evidencia la decisión de reservar el aprendizaje automático para roles acotados y verificados, no como motor de decisión; (iv) la transparencia, la reproducibilidad, la ejecución local y la auditabilidad por un clínico son requisitos que, en este

dominio, priman sobre la sofisticación del modelo; y (v) la validación cruzada estratificada resulta indispensable para reportar métricas honestas en NLP clínico con fuerte desbalance de clases.

Trabajo futuro

Se identifican las siguientes líneas: (i) validación clínica formal con radiólogos chilenos sobre las alertas generadas y refinamiento de la tabla normativa con retroalimentación local; (ii) re-evaluación del sistema sobre corpus chilenos cuando estén disponibles; (iii) una línea de *predicción* del BI-RADS desde los hallazgos –distinta de la extracción actual– orientada a detectar mis-categorizaciones. En un experimento exploratorio en esta dirección se buscó optimizar el entrenamiento aplicando múltiples técnicas: eliminación de las fuentes de fuga de etiqueta (enmascaramiento del número declarado y remoción de la recomendación, que actúa como proxy determinista de la categoría), deduplicación del corpus, sustitución del modelo base por uno clínico en español (*bsc-bio-ehr-es*), manejo del desbalance mediante *focal loss* y ponderación por clase, y calibración de confianza. Pese a ello, el Macro F1 alcanzó 0,62, con buen desempeño en las clases mayoritarias pero colapso en las minoritarias (BI-RADS 6 nunca fue predicho, con solo 5 ejemplos). Este resultado *corrobora que la limitación principal reside en el dataset* –la escasez de ejemplos en las categorías clínicamente críticas– y no en la técnica de entrenamiento, motivando como prioridad la recolección o generación validada clínicamente de más casos de dichas clases; (iv) extensión del pipeline a informes de ecografía mamaria; (v) integración con sistemas RIS/PACS hospitalarios; y (vi) un dashboard interactivo para la visualización de alertas en flujos asistenciales (en desarrollo).

REFERENCES

- [1] J. S. Ancker, A. Edwards, S. Nosal, D. Hauser, E. Mauer, and R. Kaushal, "Effects of workload, work complexity, and repeated alerts on alert fatigue in a clinical decision support system," *BMC Medical Informatics and Decision Making*, vol. 17, no. 1, p. 36, 2017.
- [2] DEIS — Ministerio de Salud de Chile, "Defunciones por tumores malignos según sexo, Chile," Departamento de Estadísticas e Información de Salud, 2024.
- [3] D. A. Sippo, G. I. Warden, K. P. Andriole, R. Lacson, I. Ikuta, R. L. Birdwell, and R. Khorasani, "Automated extraction of BI-RADS final assessment categories from radiology reports with natural language processing," *Journal of Digital Imaging*, vol. 26, no. 5, pp. 989–994, 2013.
- [4] G. Kuling, B. Curpen, and A. L. Martel, "BI-RADS BERT and using section segmentation to understand radiology reports," *Journal of Imaging*, vol. 8, no. 5, p. 131, 2022.
- [5] P. López-Úbeda, T. Martín-Noguerol, and A. Luna, "Automatic classification and prioritisation of actionable BI-RADS categories using natural language processing models," *Clinical Radiology*, vol. 79, pp. e1–e7, 2024.
- [6] Ministerio de Salud de Chile, "Guía de práctica clínica auge: Cáncer de mama," MINSAL, Santiago de Chile, 2015.
- [7] W. A. Berg, C. Campassi, P. Langenberg, and M. J. Sexton, "Breast imaging reporting and data system: inter- and intraobserver variability in feature analysis and final assessment," *American Journal of Roentgenology*, vol. 174, no. 6, pp. 1769–1777, 2000.
- [8] E. Lazarus, M. B. Mainiero, B. Schepps, S. L. Koelliker, and L. S. Livingston, "BI-RADS lexicon for US and mammography: interobserver variability and positive predictive value," *Radiology*, vol. 239, no. 2, pp. 385–391, 2006.

- [9] American College of Radiology, *BI-RADS® Atlas — Breast Imaging Reporting and Data System*, 5th ed. American College of Radiology, 2013.
- [10] Congreso Nacional de Chile, “Ley n.º 19.628 sobre protección de la vida privada,” Biblioteca del Congreso Nacional de Chile, 1999.
- [11] J. L. Vázquez Noguera, A. Torres-Hurtado, H. Gómez-Adorno, J. C. Mello-Román, E. J. Fleitas-Alvarez, F. F. Espinola Schulze, M. Garcia-Torres, C. D. Méndez Gaona, P. E. Gardel Sotomayor, S. Vázquez Noguera, N. E. Zaracho Amarilla, and O. W. Gamarra Esquivel, “Mammography reporting dataset with BI-RADS system for natural language processing applications: Addressing public data gaps in Spanish,” *Data in Brief*, vol. 61, p. 111761, 2025.
- [12] M. Sokolova and G. Lapalme, “A systematic analysis of performance measures for classification tasks,” *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009.
- [13] J. Cañete, G. Chaperon, R. Fuentes, J.-H. Ho, H. Kang, and J. Pérez, “Spanish pre-trained BERT model and evaluation data,” in *PML4DC at ICLR 2020*, 2020.
- [14] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of NAACL-HLT 2019*, 2019, pp. 4171–4186.
- [15] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems 30 (NeurIPS)*, 2017, pp. 5998–6008.
- [16] V. Sanh, L. Debut, J. Chaumond, and T. Wolf, “DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter,” *arXiv preprint arXiv:1910.01108*, 2019.
- [17] R. Kohavi, “A study of cross-validation and bootstrap for accuracy estimation and model selection,” *Proceedings of IJCAI*, vol. 14, no. 2, pp. 1137–1145, 1995.
- [18] V. I. Levenshtein, “Binary codes capable of correcting deletions, insertions and reversals,” *Soviet Physics Doklady*, vol. 10, no. 8, pp. 707–710, 1966.
- [19] L. A. Ramshaw and M. P. Marcus, “Text chunking using transformation-based learning,” in *Proceedings of the Third Workshop on Very Large Corpora*, 1995, pp. 82–94.
- [20] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, pp. 1–21, 2012.